

Projet de Cybersécurité : Détection d’Intrusions Intelligente

Phase 1 : Analyse et Compréhension du Contexte

VOTRE NOM ICI

29 novembre 2025

1 Introduction

Ce projet vise à concevoir un Système de Détection d’Intrusions (IDS) de nouvelle génération, basé sur l’Intelligence Artificielle. Contrairement aux systèmes classiques qui reposent sur des signatures statiques, notre approche utilise le Machine Learning pour identifier des comportements anormaux, permettant ainsi la détection d’attaques inconnues (*Zero-day*) et sophistiquées.

Cette première phase définit le périmètre technique, les données utilisées et la taxonomie des menaces ciblées.

2 Étude de l’Infrastructure et du Dataset

Étant donné que le développement du modèle repose sur des données d’apprentissage, l’analyse de l’infrastructure correspond à l’environnement de génération du dataset choisi : **CICIDS2017** (créé par l’Institut Canadien de Cybersécurité).

2.1 Topologie du Réseau Simulé

Le dataset a été généré sur une infrastructure réseau complète simulant un environnement d’entreprise réaliste, divisé en deux zones distinctes :

- **Le Réseau Attaquant (Extérieur)** : Une machine Kali Linux simulant des attaques provenant d’Internet.
- **Le Réseau Victime (Interne)** : Un réseau d’entreprise protégé par un pare-feu, comprenant :
 - Des serveurs (Web, Email, FTP).
 - Des postes de travail utilisateurs (Windows, Ubuntu, macOS).
 - Des équipements réseaux (Switchs, Routeurs, Pare-feu).

Cette architecture permet de capturer un trafic mixte contenant à la fois des interactions utilisateurs légitimes (HTTP, HTTPS, SSH, Emails) et des flux malveillants.

3 Identification des Sources de Données

Pour l’entraînement des modèles de Machine Learning, le choix de la source de données est critique.

Données Brutes (Raw Data) : Initialement, le trafic est capturé sous forme de fichiers .pcap (Packet Capture). Bien que complets, ces fichiers sont trop volumineux et contiennent des données chiffrées (payload) difficilement exploitables directement par des modèles classiques.

Données Traitées (Flow Data) - *Choix retenu* : Nous utiliserons les données extraites sous forme de **flux réseaux (Network Flows)**.

- **Outil d'extraction :** CICFlowMeter.
- **Format :** CSV (Comma Separated Values).
- **Avantage :** Cette méthode transforme les paquets bruts en vecteurs de caractéristiques statistiques (*Features*) tels que la durée du flux, l'écart-type de la taille des paquets, le nombre de drapeaux SYN/ACK, etc. C'est ce format structuré qui alimentera nos algorithmes.

4 Analyse Comparative des Standards IDS

Afin de justifier notre approche, nous avons comparé les solutions du marché avec la solution proposée.

Type d'IDS	Outils	Méthode	Limites
Basé sur Signature	Snort, Suricata	Compare le trafic à une base de données de signatures connues (Blacklist).	Inefficace contre les attaques nouvelles (Zero-day) ou modifiées (polymorphes).
Basé sur l'Anomalie	IA / ML	Apprend le profil du trafic "normal" et alerte sur toute déviation.	Risque de taux de faux positifs plus élevé si le modèle est mal calibré.

TABLE 1 – Comparaison SIDS vs AIDS (Notre projet)

Conclusion : Le projet se positionne comme une solution d'AIDS (*Anomaly-based IDS*) visant à compléter les défenses traditionnelles.

5 Définition des Menaces (Taxonomie MITRE ATT&CK)

Le système sera entraîné pour détecter et classer plusieurs familles d'attaques présentes dans le dataset CICIDS2017. Nous avons mappé ces attaques au framework standard **MITRE ATT&CK** pour assurer la pertinence professionnelle du projet.

Label Dataset	Description	ID MITRE	Technique
FTP/SSH-Patator	Brute force mot de passe	T1110	Brute Force
DoS / DDoS	Saturation des ressources	T1498	Denial of Service
PortScan	Balayage des ports	T1595	Active Scanning
Bot	Machine zombie (C2)	T1071	Application Layer Protocol
Web Attack	Injection SQL, XSS	T1190	Exploit Public-Facing App
Infiltration	Exécution de code	T1204	User Execution

TABLE 2 – Correspondance des attaques avec MITRE ATT&CK

6 Conclusion de la Phase 1

Cette phase d'analyse a permis de définir le cadre du projet. Nous travaillerons sur des données de flux (CSV) issues de l'environnement CICIDS2017, en utilisant des algorithmes d'apprentissage supervisé pour classer le trafic selon la taxonomie MITRE identifiée. La prochaine étape (Phase 2) consistera à préparer ces données pour l'entraînement.